Dataset

O dataset escolhido foi “European Football Injuries (2020-2025)”, que está disponível na plataforma Kaggle. O dataset fornece dados e um panorama de lesões dos jogadores das cinco principais ligas europeias (Premier league, La Liga, Ligue One, Bundesliga e Serie A) no período entre 2020 e 2025.
Link de acesso: https://www.kaggle.com/datasets/sananmuzaffarov/european-football-injuries-2020-2025

Problema e objetivo

O objetivo do projeto é analisar, através do aprendizado não supervisionado e clusterização, se existem perfis distintos de recorrência de lesão entre os jogadores das 5 principais ligas europeias do período entre 2020 e 2025, considerando a frequência de lesões ao longo do período, o intervalo de tempo entre uma lesão e a seguinte, e a tendência de reincidir na mesma região do corpo.

Exploração e preparação dos dados

O primeiro passo foi a contagem e visualização de registros no dataset, que contabilizou 15.603 registros com nenhum valor nulo.

```
Total de registros: 15603
                                          0                    1  \
Season                                20/21                20/21
Injury               Syndesmosis ligament tear          Knee injury
Days                                43 days              37 days
Games missed                              9                    6
injury_from_parsed                1/28/2021            3/7/2021
injury_until_parsed               3/11/2021            4/12/2021
player_name                 Alexander Nübel  Ron-Thorben Hoffmann
player_age                               24                   22
player_position                  Goalkeeper           Goalkeeper
club                           Bayern Munich        Bayern Munich
league                            Bundesliga           Bundesliga

                                  2             3              4
Season                        20/21         20/21          20/21
Injury                  Corona virus        bruise  Ligament injury
Days                         21 days       8 days        22 days
Games missed                       4             2              2
injury_from_parsed         2/17/2021     11/6/2020      7/26/2020
injury_until_parsed         3/9/2021    11/13/2020      8/16/2020
player_name          Benjamin Pavard  Benjamin Pavard  Benjamin Pavard
player_age                        25            25             25
player_position          Centre-Back   Centre-Back    Centre-Back
club                   Bayern Munich  Bayern Munich  Bayern Munich
league                    Bundesliga    Bundesliga     Bundesliga
```

```
Valores nulos por coluna:
Season                0
Injury                0
Days                  0
Games missed          0
injury_from_parsed    0
injury_until_parsed   0
player_name           0
player_age            0
player_position       0
club                  0
league                0
days_num              0
injury_lower          0
```

Após isso se iniciou a etapa de tratamento e limpeza dos dados de algumas colunas para não influenciar negativamente a análise posterior, tratamentos e padronizações que foram feitas incluem:

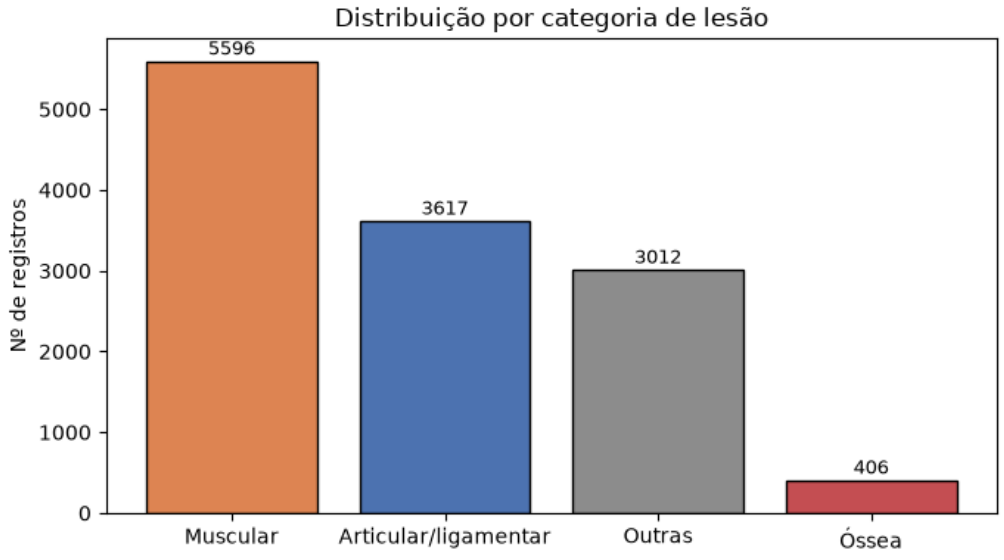
- Valores da Coluna *Injury* foram todos padronizados para ficarem somente com letras minúsculas, pois alguns valores apenas por estarem com letras maiúsculas e minúsculas, como “Ankle sprain” e “ankle sprain”, eram tratados como diferentes.

- Coluna *Days* estava com valores como “43 days”, “37 days”, “22 days”, então removemos o “days” e convertemos os valores da coluna para Integer.

- Colunas *injury_from_parsed* e *injury_until_parsed* estavam como valores do tipo String, convertemos para datetime, pois será necessário para calcular o intervalo entre o fim de uma lesão e o início da lesão seguinte do mesmo jogador.

- Como estamos priorizando apenas lesões físicas, removemos os registros sobre doenças ou outros tipos de afastamentos (como dor de barriga).

- Por último, foi feita uma separação de todas as lesões para as categorias “muscular”, “articular” e “ossea”, pois dessa forma facilita a comparação para checar se houve reincidência de lesão na mesma região do corpo. Não dá para fazer uma comparação normal de String porque seria somente uma comparação de caracteres, sem contexto, por exemplo, adductor e hamstring são músculos, mas uma comparação de String ele não entende como reincidência porque “adductor” == “hamstring” daria False. No final, os valores ficaram distribuidos da seguinte forma:



Após o tratamento e limpeza dos dados, se inicia a parte de agregação dos dados para que seja feito depois a análise do jogador e não da lesão em si. Nessa etapa de agregação, é calculado o número total de lesões, a idade, o intervalo médio entre o fim de uma lesão e o início da seguinte, o percentual de vezes em que a lesão seguinte é da mesma categoria, ou seja, reincidência, e

a média de dias parados. Importante destacar que jogadores com apenas uma lesão foram descartados, pois é necessário que o jogador tenha tido pelo menos duas lesões no período, para ser possível analisar se houve reincidência.

Antes da etapa de padronização, é realizado uma fase de transformação utilizando o cálculo de log1p nos valores das colunas *intervalo_medio* e *media_dias_parado*, para comprimir os outliers que poderiam distorcer a análise do K-means na busca por jogadores semelhantes. Após isso começa a etapa de padronização com StandardScaler, que faz com que todas as colunas numéricas utilizadas passem a ter média igual a 0 e o desvio padrão igual a 1, colocando todas as colunas na mesma escala, desse jeito nenhuma coluna influencia o cálculo de distância do K-means.

Estratégia experimental

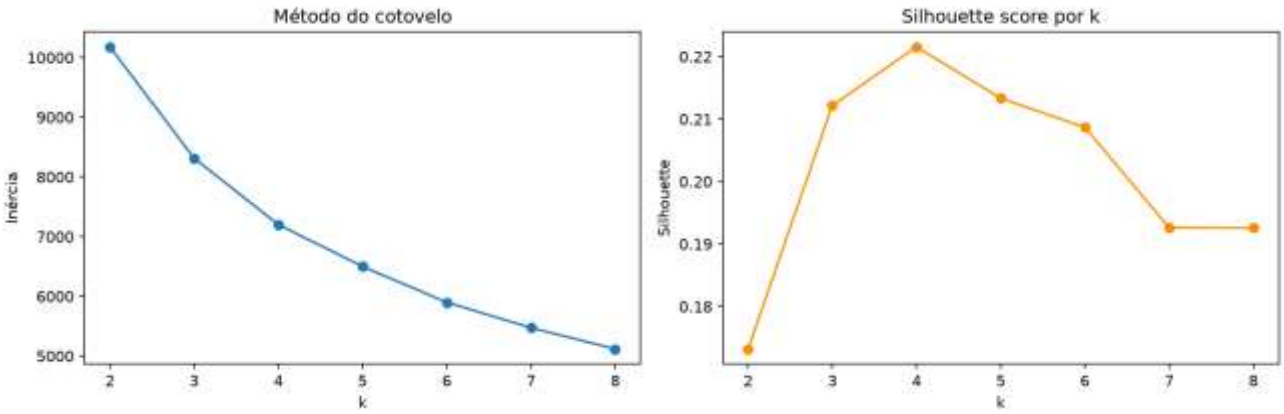
Por conta de ser um aprendizado não supervisionado, não tem divisão de treino e teste, já que não tem rótulos de referências para o desempenho do modelo ser validado. Ao invés disso, foi utilizado métricas internas de avaliação de clusters, o método do cotovelo e o Silhouette score, que vão ser mais aprofundadas na seção de Avaliação.

Modelagem

Foi utilizado o algoritmo K-Means para o agrupamento, por ser mais adequado ao formato de dados utilizado, que forma grupos bem definidos. O principal motivo de se utilizar ele e não DBSCAN se deve ao fato de que o DBSCAN descarta quase todos os jogadores por tratar vários como "ruídos" (no caso, valores cuja distância não bate no raio necessário para serem considerados viáveis). Em relação aos principais hiperparâmetros, o K-Means exige três, sendo eles o *n_clusters*, que seria o número de clusters, nesse caso foi escolhido 4 (o motivo será mais detalhado na seção de Avaliação), o *random_state*, que seria o ponto inicial dos centroides, foi escolhido o número 42 por convenção (referência a "Guia do Mochileiro das Galáxias") e por fim o *n_limit*, que determina o número de vezes que o fluxo do K-Means irá se repetir, foi escolhido o valor 10 para aumentar as chances de obter um resultado bom no final do ciclo.

Avaliação

Como foi mencionado antes, foram utilizadas métricas internas de avaliação, métodos cotovelo e o Silhouette score, para sustentar a escolha do número de Ks, que nesse caso foi 4.



Método do cotovelo: Método utilizado para medir quanto os dados ficam espalhados conforme o número de clusters aumenta, sendo que a primeira diferença (nesse caso, k=2 para k=3) serve mais para filtrar, não é possível utilizar como critério pois geralmente a primeira filtragem tende a ser grande, independentemente da estrutura dos dados, já que tira a diferença mais óbvia entre os dados. Apenas pelo método do cotovelo fica uma confusão se o número ideal deve ser 4, 5 ou 6, por isso, foi necessário utilizar também o método Silhouette score.

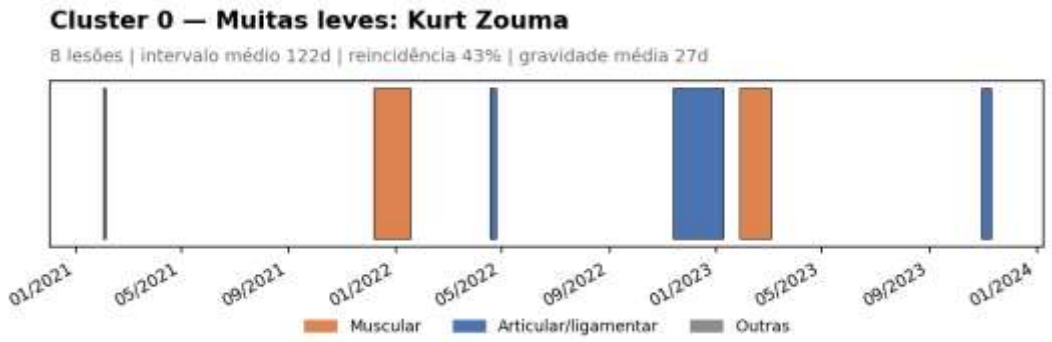
Silhouette score: Nesse método, se mede o quanto um jogador está bem alocado no cluster atual ou se faz mais sentido ele ir para um cluster vizinho. No cálculo realizado o valor pode variar entre -1 e 1, sendo que quanto mais perto de 1, melhor. No teste do Silhouette o melhor resultado foi justamente com k=4 com valor 0.22 (média de todos os valores individuais de cada jogador), a partir do k=5 o valor começa a diminuir, ou seja, piora a separação dos clusters.

Pelo complemento de um teste com o outro, cotovelo indicando uma faixa razoável entre 4 e 6 e Silhouette indicando uma média única e mais alta em k=4, acaba reforçando que a melhor escolha para o número do k deve ser 4.

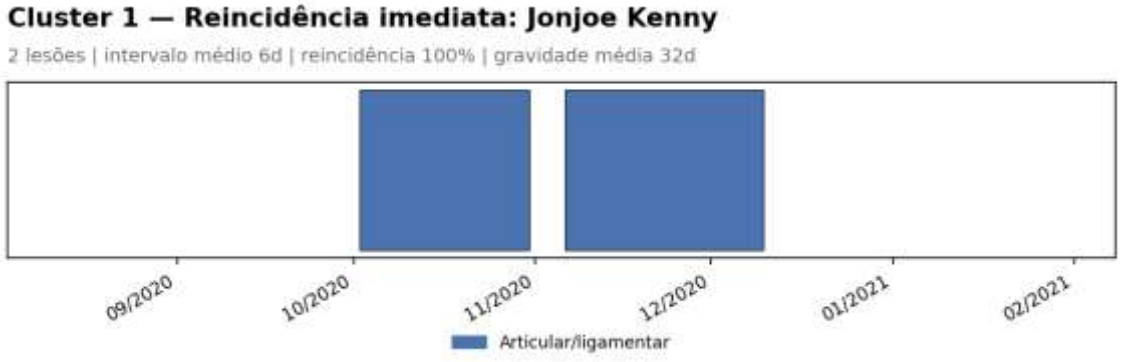
Análise dos resultados

```
=== Perfil de cada cluster ===
         n_lesoes  idade  intervalo_medio  pct_reincidencia  media_dias_parado  n_jogadores
cluster
0             7.4   29.7            165.2               0.5               30.1          914
1             2.2   25.0              5.4               0.9               42.4          154
2             3.2   25.7            250.7               0.8               52.8          714
3             2.8   26.6            290.1               0.0               47.6          686
```

Cluster 0 | Maior número de lesionados, mas com lesões leves: É o cluster com a maior média de lesões (7.4) e de idade (29.7) e é o que contém o grupo de jogadores que mais acumula lesões ao longo do tempo, porém, são lesões com gravidade baixa, visto que esse grupo de jogadores também é com a menor média de dias parados (30.1), ou seja, maior frequência de lesões, mas são lesões leves. Abaixo um exemplo com o jogador Kurt Zouma:



Cluster 1 | Reincidência imediata: É o cluster com o intervalo médio mais baixo de todos, de apenas 5.4 dias e 90% de reincidência, ou seja, um jogador desse grupo acaba de voltar de uma lesão e pouco tempo depois já sofre outra lesão, e na maioria das vezes, na mesma região do corpo. Abaixo um exemplo com o jogador Jonjoe Kenny:



Cluster 2 | Lesões espaçadas e graves: Nesse cluster o intervalo médio entre as lesões é alto (250.7) e a gravidade é a alta também, já que a média de dias parado é a maior entre todos os clusters, chegando a 52.8 dias, então um jogador nesse cluster se lesiona, fica um bom tempo sem jogar, mas quando se lesiona de novo tende a ser uma lesão grave e como o valor de reincidência chega a 80%, há uma chance bem alta de ser na mesma região da lesão anterior.



Cluster 3 | Lesões sem conexão: Esse é o cluster com o maior intervalo médio (290.1) e possui 0% de reincidência, ou seja, os jogadores desse cluster raramente sofrem duas lesões seguidas na mesma região do corpo. Abaixo um exemplo com o jogador David Jurásek

